

Artificial Intelligence

Lecture 08 – Visión por Computadora
en 180 min






Contenido


1. ¿Que es la visión artificial?
2. Problemas en la visión artificial
3. Procesamiento y caracterización de imagenes
4. Convolutional Neural Networks en la Vision Artificial
5. Transfer Learning
6. YOLO



¿QUÉ ES LA VISIÓN ARTIFICIAL?



¿QUÉ ES LA VISIÓN ARTIFICIAL?



PROCESAMIENTO DE IMÁGENES:

Es un proceso mediante el cual se toma una imagen y se produce una versión modificada de esta imagen

ANÁLISIS DE IMÁGENES:

Proceso mediante el cual a partir de una imagen se obtiene una medición de los objetos en la imagen.

RECONOCIMIENTO DE PATRONES:


Proceso mediante el cual a partir de una imagen se obtiene una medición, y se hace una interpretación y/o se toma decisión.



PROBLEMAS EN LA VISIÓN ARTIFICIAL


Dotar a las Máquinas con la capacidad de “ver” NO es una tarea fácil

1. Cambios de Iluminación
2. Cambios en la Escala
3. Deformación



PROBLEMAS EN LA VISIÓN ARTIFICIAL

- 4. Oclusión de objetos
- 5. Movimiento
- 6. Distinción de Objetos



PROCESAMIENTO Y CARACTERIZACIÓN DE IMÁGENES

Reducción de resolución -> Entrenamiento más rápido




Imagen Original



Cada 3 Pixels



Cada 10 Pixels



PROCESAMIENTO Y CARACTERIZACIÓN DE IMÁGENES

Reducción de ruido -> Mayor Calidad de Imagen

Consiste, en general, en tomar un arreglo de pixels como entrada y producir otro arreglo de pixels como salida, el cual de alguna manera representa una mejora del arreglo original.



Imagen Original




Eliminar ruido



PROCESAMIENTO Y CARACTERIZACIÓN DE IMÁGENES


Segmentación

Se divide la imagen en regiones homogéneas que corresponden con los objetos contenidos en ella.



Análisis de segmentos

Se obtienen medidas de características de los objetos segmentados, por ejemplo, características de color, de textura y/o de forma (área, perímetro, número de agujeros, ...)




CNN's en la Visión Artificial

Antes





Ahora




CNN's en la Visión Artificial

A typical ML framework




A typical DL framework [convolutional neural networks (CNN) shown here]



CNN's en la Visión Artificial

Dentro del proceso de convolución ocurre el **reconocimiento de patrones** como parte fundamental del sistema de visión artificial, en la que a partir de las características encontradas, los posibles objetos se estiman las salidas del modelo.





CNN Explainer: <https://poloclub.github.io/cnn-explainer/>



CNN's en la Visión Artificial



Si los descriptores elegidos son adecuados, objetos similares tendrán patrones próximos en el espacio de características.



- Patrones que describen objetos de una misma clase, presentan características similares.
- Patrones que describen objetos de diferentes clases presentan características diferenciadas.




CNN's en la Visión Artificial



CNN's en la Visión Artificial

AlexNET


Architecture



Parameters: 60 million

VGG-16

Architecture




Parameters: 138 million




CNN's en la Visión Artificial

Inception


Architecture




ResNet





ResNet 34
residual block



ResNet 50
residual block




Transfer Learning




Transfer Learning

Assumes that $D_S = D_T$




Transfer Learning with Pre-trained Deep Learning Models as Feature Extractors




Detección de objetos- Enfoque pre-YOLO

Windows Slicing



You Only Look Once (Yolo)



YOLO es un algoritmo de *deep learning* para detección de objetos en tiempo real. Utiliza una sola red neuronal convolucional (CNN) que analiza la imagen completa una sola vez y predice simultáneamente bounding boxes y clases de objetos.



You Only Look Once (Yolo)


$$\text{Grid Cells} = \frac{\text{Image Dimensions}}{\text{Grid Size}}$$

A diferencia de métodos tradicionales que evalúan múltiples regiones de la imagen, YOLO divide la imagen en una cuadrícula y realiza predicciones directas, lo que lo hace extremadamente rápido y eficiente.



You Only Look Once (Yolo)

La imagen se divide en una grilla de celdas (por ejemplo 3×3). Cada celda es responsable de detectar objetos cuyo **centro** caiga dentro de ella. Para cada celda, la red predice simultáneamente: dónde está el objeto, qué tan grande es, y qué clase es.



El tensor de salida tiene forma **[3, 3, 8]**

→ 3 filas × 3 columnas de la grilla

→ 8 valores por celda:

x, y — centro del obj. dentro de la celda (0-1)


w, h — tamaño del bbox relativo a imagen (0-1)

conf — confianza de que hay un objeto (0-1)

p_persona, p_auto, p_perro — clase (suman 1)




You Only Look Once (Yolo)



índice	campo	valor	significado
[0]	x	0.50	centro X dentro de la celda (0=izq, 1=der)
[1]	y	0.50	centro Y dentro de la celda (0=arr, 1=aba)
[2]	w	0.00	ancho del bbox relativo a imagen
[3]	h	0.00	alto del bbox relativo a imagen
[4]	conf	0.02	¿hay objeto aquí?
[5]	p_persona	0.33	prob. clase persona
[6]	p_auto	0.34	prob. clase auto
[7]	p_perro	0.33	prob. clase perro




You Only Look Once (Yolo)



índice	campo	valor	significado
[0]	x	0.50	centro X dentro de la celda (0=izq, 1=der)
[1]	y	0.50	centro Y dentro de la celda (0=arr, 1=aba)
[2]	w	0.00	ancho del bbox relativo a imagen
[3]	h	0.00	alto del bbox relativo a imagen
[4]	conf	0.02	¿hay objeto aquí?
[5]	p_persona	0.33	prob. clase persona
[6]	p_auto	0.34	prob. clase auto
[7]	p_perro	0.33	prob. clase perro



You Only Look Once (Yolo)



índice	campo	valor	significado
[0]	x	0.43	centro X dentro de la celda (0=izq, 1=der)
[1]	y	0.78	centro Y dentro de la celda (0=arr, 1=aba)
[2]	w	0.23	ancho del bbox relativo a imagen
[3]	h	0.44	alto del bbox relativo a imagen
[4]	conf	0.91	¿hay objeto aquí?
[5]	p_persona	0.88	prob. clase persona
[6]	p_auto	0.06	prob. clase auto
[7]	p_perro	0.06	prob. clase perro

Detección confirmada

Clase: **persona** con 88% · confianza objeto: 91%

Score final = conf × p_clase = 0.91 × 0.88 = **0.801**


You Only Look Once (Yolo)

	col 0	col 1	col 2
fila 0	conf: 0.02 x=0.50 y=0.50 w=0.00 h=0.00 👤0.33 🚗0.34 🐕0.33	conf: 0.91 x=0.43 y=0.78 w=0.23 h=0.44 👤0.88 🚗0.06 🐕0.06	conf: 0.03 x=0.50 y=0.50 w=0.00 h=0.00 👤0.34 🚗0.33 🐕0.33
fila 1	conf: 0.04 x=0.50 y=0.50 w=0.00 h=0.00 👤0.33 🚗0.33 🐕0.34	conf: 0.05 x=0.50 y=0.50 w=0.00 h=0.00 👤0.35 🚗0.32 🐕0.33	conf: 0.08 x=0.50 y=0.50 w=0.00 h=0.00 👤0.20 🚗0.10 🐕0.70
fila 2	conf: 0.03 x=0.50 y=0.50 w=0.00 h=0.00 👤0.33 🚗0.34 🐕0.33	conf: 0.04 x=0.50 y=0.50 w=0.00 h=0.00 👤0.34 🚗0.33 🐕0.33	conf: 0.87 x=0.38 y=0.42 w=0.28 h=0.29 👤0.05 🚗0.04 🐕0.91



You Only Look Once (Yolo)

¿De dónde vienen x , y , w , h , $conf$? — del entrenamiento



¿Cómo se mantienen entre 0 y 1?

x , y , $conf$ → $\text{sigmoid}(\text{output})$ siempre en $[0, 1]$
 w , h → sin sigmoid, valor libre (puede ser > 1)
clases → $\text{softmax}(\text{outputs})$ suman 1.0

backprop ajusta los pesos de la FC
para que la próxima vez prediga valores más cercanos al gt



BIBLIOGRAFÍA

- Digital Image Processing, Gonzalez and Woods, 2008
- Image Processing, Analysis and Machine Vision, Sonka and Hlavac, 2008
- Visión por Computador. Imágenes Digitales y Aplicaciones, Pajares y de la Cruz, 2008
- Computer Vision: Algorithms and Applications. Richard Szeliski. 2010.
- Feature extraction & image processing. Nixon, M. & Aguado, A. (2008).
- Image Processing: The Fundamentals - Second Edition, Petrou, M. & Petrou, C. (2010).
- Programming Computer Vision with Python. Jan Erik Solem. 2012.
- A Comprehensive Hands-on Guide to Transfer Learning with Real-World Applications in Deep Learning, Sarkar 2018
- Common architectures in convolutional neural networks. Jeremy Jordan, 2018
- Best deep CNN architectures and their principles: from AlexNet to EfficientNet, Nikolas Adaloglou, 2021
- Computer Vision and Convolutional Neural Networks,
<https://encyclopedia.pub/entry/34229>
- Computer Vision: YOLO: Grid Cells and Anchor boxes, Ayush Yajnik, 2023

